

## Questão 3

Shai Vaz, Alexandre Almeida, Heron Goulart, João Pedro Pedrosa, Roberto Orenstein

2023-10-04

### Questão 3

#### Dados

```
ipca <- rbcB::get_series(code = 433, start_date = "2001-07-01", end_date = "2023-07-01")

ipca <- ipca %>%
  set_names(c("Date", "MoM")) %>%
  mutate(
    MoM = ifelse(Date == "2001-07-01", 0, MoM),
    Index = 100 * cumprod(MoM / 100 + 1),
    IndexLog = log(Index),
    IndexLogDiff = c(NA, diff(IndexLog))
  )
```

Repare que ao realizar as transformações indicadas no enunciado, obtivemos exatamente o mesmo dado inicial, afinal a diferença de log é uma aproximação para uma variação percentual. Ou seja, apenas perdemos uma observação e pioramos a qualidade do dado porque a aproximação pela primeira diferença dos logs introduz um erro.


Agora vamos criar uma variável no formato de série temporal.

```
IndexLogDiff_ts <- ts(ipca$IndexLogDiff, start = c(2001, 7), frequency = 12)
IndexLogDiff_ts <- na.omit(IndexLogDiff_ts)
```

Vamos visualizar a série temporal.

```
plot(
  IndexLogDiff_ts*100,
  xlab = "Data",
  ylab = "Variação na Inflação",
  main = "Log-Diferença do Índice de Inflação"
)
```

## Log-Diferença do Índice de Inflação



### Teste Phillips Perron

```
pp_test <- pp.test(IndexLogDiff_ts)
```

```
tidy(pp_test) %>%  
  kable(  
    col.names = c(  
      "Statistic: Dickey-Fuller Z (alpha)",  
      "P Value",  
      "Parameter: Truncation lag",  
      "Method",  
      "Alternative Hypothesis"  
    ),  
    caption = "Teste Philips Perron"  
  )
```

Table 1: Teste Philips Perron

Statistic: Dickey-Fuller Z (alpha)	P Value	Parameter: Truncation lag	Method	Alternative Hypothesis
-95.03949	0.01	5	Phillips-Perron Unit Root Test	stationary

Ao analisarmos o p-value do teste de raiz unitária de Phillips-Perron, podemos rejeitar a hipótese nula e concluir que a série é estacionária.

## Teste de Dickey-Fuller aumentado

```
adf_test <- adf.test(IndexLogDiff_ts, alternative = "stationary", k = 12)
```

```
tidy(adf_test) %>%  
  kable(  
    col.names = c(  
      "Statistic: Dickey-Fuller",  
      "P Value",  
      "Parameter: Lag order",  
      "Method",  
      "Alternative Hypothesis"  
    ),  
    caption = "Teste Dickey-Fuller Aumentado"  
  )
```

Table 2: Teste Dickey-Fuller Aumentado


Statistic: Dickey-Fuller	P Value	Parameter: Lag order	Method	Alternative Hypothesis
-3.563361	0.0371268	12	Augmented Dickey-Fuller Test	stationary

O teste de Dickey-Fuller aumentado que aplicamos à série temporal indica que a série é estacionária. Isso é sustentado pelo valor-p, que é menor do que o nível de significância comum. Portanto, podemos rejeitar a hipótese de que a série possui uma raiz unitária.

## Funções de Autocorrelação


```
acf(IndexLogDiff_ts,  
  main = "Autocorrelation Function: Série Log-Dif")
```

### Autocorrelation Function: Série Log-Dif



```
pacf(IndexLogDiff_ts,  
      main = "Partial Autocorrelation Function: Série Log-Dif")
```

## Partial Autocorrelation Function: Série Log-Dif



## Modelo ARMA

### Decisão pela FAC/FACP

Pelo FAC, identificamos que a ordem do MA é 4 e, pela FACP, que a ordem do AR é 1. No entanto, vamos fazer modelos alternativos para escolher o melhor pelo critério da informação.

```
# Modelo 1
modelo_arma4 <- arima(IndexLogDiff_ts, order = c(1, 0, 4))

# Modelo 2
modelo_arma1 <- arima(IndexLogDiff_ts, order = c(1, 0, 1))

# Modelo 3
modelo_arma2 <- arima(IndexLogDiff_ts, order = c(1, 0, 2))

# Modelo 4
modelo_arma3 <- arima(IndexLogDiff_ts, order = c(1, 0, 3))
```

```
stargazer(
  modelo_arma1,
  modelo_arma2,
  modelo_arma3,
  modelo_arma4,
```

```

header = FALSE,
float = FALSE,
dep.var.caption = "Models",
dep.var.labels = "",
column.labels = c(
  "ARIMA(1,0,1)",
  "ARIMA(1,0,2)",
  "ARIMA(1,0,3)",
  "ARIMA(1,0,4)"
),
title = "Resultados dos Modelos ARMA"
)

```

	Models			
	ARIMA(1,0,1)	ARIMA(1,0,2)	ARIMA(1,0,3)	ARIMA(1,0,4)
	(1)	(2)	(3)	(4)
ar1	0.669*** (0.069)	0.658*** (0.092)	0.602*** (0.119)	0.367** (0.171)
ma1	-0.029 (0.092)	-0.019 (0.107)	0.028 (0.126)	0.265 (0.171)
ma2		0.015 (0.077)	0.053 (0.087)	0.193* (0.104)
ma3			0.063 (0.077)	0.189** (0.081)
ma4				0.181** (0.077)
intercept	0.005*** (0.001)	0.005*** (0.001)	0.005*** (0.001)	0.005*** (0.001)
Observations	264	264	264	264
Log Likelihood	1,158.117	1,158.136	1,158.449	1,160.557
$\sigma^2$	0.00001	0.00001	0.00001	0.00001
Akaike Inf. Crit.	-2,308.234	-2,306.271	-2,304.898	-2,307.113

Note:

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

### Auto Arima (critérios de informação)

Utilizaremos a função `auto.arima`, que, de forma automática, calcula todos os modelos dentro de limites dados, calcula seus critérios de informação e escolhe o modelo que minimiza. Aqui, escolhemos os limites de 5 lags para cada parte do modelo (AR e MA).

```

modelo_arma_auto <- auto.arima(
  max.p = 5,
  max.q = 5,
  IndexLogDiff_ts,

```

```
seasonal = FALSE,
stepwise = FALSE,
approximation = FALSE,
ic = "bic"
)
```

```
tidy(modelo_arma_auto) %>%
  kable(
    col.names = c(
      "Term",
      "Estimate",
      "Standard Error"
    ),
    caption = "Information Criteria Minimizer Model"
  )
```

Table 3: Information Criteria Minimizer Model

Term	Estimate	Standard Error
ar1	0.6520244	0.0464532
intercept	0.0050400	0.0005318

Ele sugere que o melhor modelo é, na realidade, o AR(1). Isso ocorre utilizando qualquer dos três critérios como base (AIC, BIC ou AICc). Vamos visualizar, aqui, os modelos pelos critérios da informação. Salvaremos esse modelo como modelo\_arma5.

```
modelo_arma5 <- arima(IndexLogDiff_ts, order = c(1, 0, 0))
```

## Critério da Informação

Vamos olhar agora, todos os modelos juntos:

```
stargazer(m5,m1,m2,m3,m4,
  header = FALSE,
  float = FALSE,
  dep.var.caption = "Models",
  dep.var.labels = "",
  column.labels = c(
    "AR(1)",
    "ARIMA(1,0,1)",
    "ARIMA(1,0,2)",
    "ARIMA(1,0,3)",
    "ARIMA(1,0,4)"
  ),
  title = "Resultados de todos os modelos realizados"
)
```

	Models				
	AR(1)	ARIMA(1,0,1)	ARIMA(1,0,2)	ARIMA(1,0,3)	ARIMA(1,0,4)
	(1)	(2)	(3)	(4)	(5)
ar1	0.652*** (0.046)	0.669*** (0.069)	0.658*** (0.092)	0.602*** (0.119)	0.367** (0.171)
ma1		-0.029 (0.092)	-0.019 (0.107)	0.028 (0.126)	0.265 (0.171)
ma2			0.015 (0.077)	0.053 (0.087)	0.193* (0.104)
ma3				0.063 (0.077)	0.189** (0.081)
ma4					0.181** (0.077)
intercept	0.005*** (0.001)	0.005*** (0.001)	0.005*** (0.001)	0.005*** (0.001)	0.005*** (0.001)
Observations	264	264	264	264	264
Log Likelihood	1,158.069	1,158.117	1,158.136	1,158.449	1,160.557
$\sigma^2$	0.00001	0.00001	0.00001	0.00001	0.00001
Akaike Inf. Crit.	-2,310.138	-2,308.234	-2,306.271	-2,304.898	-2,307.113

Note:

\*p<0.1; \*\*p<0.05; \*\*\*p<0.01

Note que o modelo que escolhemos originalmente, tem a maior log verossimilhança! Este seria o melhor modelo, portanto, se o critério de decisão fosse esse. Mas ao utilizarmos o critério de informação, punimos o modelo pelo aumento na quantidade de parâmetros.

Decidindo pela minimização dos critérios de informação, o modelo 5, um AR(1), é de fato o melhor modelo. Embora a análise da FAC e FACP tenha nos levado ao modelo ARMA(1,4), o modelo AR(1) é mais parcimonioso e prosseguiremos com ele.

Podemos ver isso mais claramente na tabela seguinte, apenas com os critérios.

```
bind_rows(
  glance(modelo_arma1),
  glance(modelo_arma2),
  glance(modelo_arma3),
  glance(modelo_arma4),
  glance(modelo_arma5)
) %>%
mutate(
  Model = c(
    "ARIMA(1,0,1)",
    "ARIMA(1,0,2)",
    "ARIMA(1,0,3)",
    "ARIMA(1,0,4)",
    "AR(1)"
  ),
  .before = 1
)
```



```

) %>%
select(
  c(1,3,4,5)
) %>%
kable(
  col.names = c(
    "Model",
    "Log Likelihood",
    "AIC",
    "BIC"
  ),
  caption = "Decision Criteria"
)

```

Table 4: Decision Criteria

Model	Log Likelihood	AIC	BIC
ARIMA(1,0,1)	1158.117	-2308.234	-2293.930
ARIMA(1,0,2)	1158.136	-2306.271	-2288.392
ARIMA(1,0,3)	1158.449	-2304.898	-2283.443
ARIMA(1,0,4)	1160.557	-2307.113	-2282.082
AR(1)	1158.069	-2310.138	-2299.410

## Previsão


Plotando as previsões do modelo 5 um ano a frente.

```

plot(forecast(modelo_arma5, h=12),
     main = "12 Month Forecast for AR(1)")

```

## 12 Month Forecast for AR(1)



Podemos também plotar as previsões para o modelo ARIMA(1,0,4), que foi obtido pela análise da FAC e FACP.

```
plot(forecast(modelo_arma4,h=12),  
     main = "12 Month Forecast for ARIMA(1,0,4)")
```

### 12 Month Forecast for ARIMA(1,0,4)

